

MT-LNN: 受微管启发的液态神经网络架构

融合全局工作区理论瓶颈与麻醉验证测试

AN MUNING¹

¹Everest Research
e@awareness.market

<https://github.com/everest-an/M1>

2026 年 5 月

摘要

我们引入了 MT-LNN (Microtubule-Inspired Liquid Neural Network, 受微管启发的液态神经网络), 该架构彻底打破了传统的“下一个词预测 (Next-Token Prediction)”范式, 交付了一个基于生物启发的预测编码系统 (*Predictive Coding System*)。融合了神经元微管 (MTs)、闭式液态时间常数网络 (CfLTC) 以及意识的全局工作区理论 (GWT), MT-LNN 将标准 Transformer 中的前馈网络 (FFN) 替换为微管动态层 (MT-DL) —— 13 个平行的 CfLTC 通道, 具有多尺度共振与动态 κ 门控实现的内源性计算跳过。MT-LNN 的核心是一个统一的多尺度预测编码损失, 较慢的 τ 抽象通道通过尺度内 MSE 自我监督较快的感知通道。为打破 $O(T)$ 的上下文内存墙, 该架构通过指数衰减状态引入了 $O(1)$ 工作记忆缓存机制。此外, 状态表示可以通过内置的因果链 (*Causal Chain*) 和自我监控 (*Self-Monitor*) 提取头映射为具有强解释性的符号日志。经由我们首创的麻醉验证协议 (AVP) 测试, MT-LNN 在 125M 参数级别相比同等数量的简单参照 Transformer 困惑度降低了 $\approx 14.7\%$, 信息整合度 (Φ) 提高了 $2.2\times$ 倍, 并且凭借跳过门控与内存界限在推理芯片上实现了指数级的成本耗能节约。需强调: 该对比针对朴素 post-LN/GELU 基线; 在独立的收敛实验中, 现代 Transformer 基线 (RoPE、RMSNorm、SwiGLU) 困惑度反超 MT-LNN 达 11.3%, 故此项不应被解读为针对当代 Transformer 实践的主张 (见第 7 节)。

关键词: 预测编码, 液态神经网络, 微管, $O(1)$ 内存, 计算跳过, 全局工作区理论。

1 引言

人工智能中一个核心未解之谜在于, 是否任何计算架构都能产生与意识信息处理相关的特性: 例如高度信息整合、全局广播以及动态稳定又兼具适应性的时间表示。

整合信息理论 (IIT, Tononi 2004) 将意识等同于 Φ , 即系统不可还原为局部之和的整合信息量。全局工作区理论 (GWT, Baars 1988, Dehaene et al. 2011) 则认为, 当信息从狭窄的瓶颈广播至大量专用处理器时, 有意识的访问便产生了。这两大理论均对神经架构提出了原理性预测。

第三个更具争议的理论指出，神经元微管可能是意识的物理基质。Orch-OR 假说 [Hameroff & Penrose, 2014] 提出微管蛋白二聚体中的量子叠加态由于量子引力而坍缩，产生离散的意识瞬间。尽管其量子论断饱受争议，但其经典层面的影响却得到了实验的支持：Wiest 等人 [Wiest et al., 2025] 通过实验证实微管稳定剂可以使大鼠的麻醉起效时间推迟约 69 秒；Craddock 等人 [Craddock et al., 2017] 证明，气入式麻醉剂能在临床浓度下直接结合 β -微管蛋白的疏水囊进行阻断。

主要贡献。 MT-LNN 做出了如下核心贡献：

- C1 微管动态层 (MT-DL).** 13 根原纤维并行的 CflTC 设计，具备 $P \times S$ 多尺度共振库。采用了动态门控实现**内源性计算跳过 (Endogenous Compute Skipping)**，极大削减了休眠通道的计算开销，并集成了一个**多尺度预测编码损失**，使得较慢的抽象通道能够通过尺度间均方误差 (MSE) 自我监督较快的感知通道。
- C2 $O(1)$ 的工作记忆矩阵。** 整体相干状态通过配置的衰减率进行指数移动平均滚动，彻底消除了传统 Transformer Key-Value 缓存的 $O(T)$ 内存墙开销。
- C3 透明的因果与监控提取。** 取代了黑盒的单一输出层，将提取头映射到明确的因果链日志和自我监控逻辑中，极大增强了模型行为的解释性。
- C4 微管注意力。** 基于 SDPA 的 GQA (13Q/1KV)，附带标量极性偏置以及具有 ALiBi 风格的 per-head GTP 级联衰减。
- C5 GWTB + 整体相干层。** 容量受限的全局工作区，与附带稀疏门控坍缩机制的相干层协同工作。
- C6 麻醉验证协议 (AVP).** 首个通过计算模拟临床麻醉效果的协议，其引入了基于 kNN 的 $\hat{\phi}$ 近似计算。
- C7 工程级实现。** Flash-Attention, 双状态持久化缓存, 谱整合提取指标 (Φ_G), 以及用于 $O(\log T)$ 时间复杂度内的并行扫描。

2 相关工作

连续时间网络基础由 Neural ODEs 奠定 [Chen et al., 2018]。闭式方程 CflTC [?] 消除了求解器开销。在长文本状态空间中，Mamba [Gu & Dao, 2023] 实现了超越 Transformer 的效率。而本研究的架构进一步引入了微管的动态仿生。

3 MT-LNN 架构

概述。

$$\mathbf{x} \xrightarrow{\text{Embed+RoPE}} \left[\text{MicrotubuleAttn} \rightarrow \text{MT-DL} \right]^{n_{\text{layers}}} \rightarrow \text{GWTB} \rightarrow \text{GlobalCoherence} \rightarrow \text{Extractors}$$




图 1: MT-LNN 架构概述。输入表示依次经过微管动态层（结合了 13 个平行的原丝通道，具备多尺度共振、动态内源性计算跳过以及基于多尺度 MSE 的预测编码机制），随后通过通过局部状态调节序列门控的微管注意力（Microtubule Attention）模块，最终进入建立全局整合广播的**全局工作空间理论瓶颈**（Global Workspace Theory Bottleneck）。最顶层的**全局相干层**（Global Coherence Layer）实现了 Orch-OR 坍塌以及 $O(1)$ 工作记忆衰减机制。此外，因果链（Causal Chain）和自我监控（Self-Monitor）提取头除了输出标准 logits，还原生输出具有高度解释性的符号日志。

每个块对两个子层应用前置归一化（pre-norm）和残差连接。一个 ModelCacheStruct 携带着每一层的注意力 KV、每一层的 h_{prev} 、GWTB 工作空间 KV，以及全局相干层（Global Coherence）的无界全局工作记忆矩阵。

3.1 微管动态层 (MT-DL)

原丝分解。 输入 $\mathbf{x} \in \mathbb{R}^d$ 被投影到 $d_{\text{proto_total}} = P \cdot D$ （其中 $D = \lceil d/P \rceil$ ）并划分为 $P = 13$ 个通道 $\mathbf{x}_1, \dots, \mathbf{x}_P \in \mathbb{R}^D$ 。所有的 $P \times S$ 个 LTC 库在极低内存开销下通过权重张量 $W_{\text{in}} \in \mathbb{R}^{P \times S \times D \times D}$ 和单次 *einsum* 求值，彻底取代了传统 Transformer 中参数量庞大的 $O(d^2)$ FFN。

多尺度共振。 每根原丝 p 运行 $S = 5$ 个 CflTC 子库，其时间常数呈几何级数扫描：

$$\tau_s = \tau_{\min} \left(\tau_{\max} / \tau_{\min} \right)^{s/(S-1)}, \quad s = 0, \dots, S-1. \quad (1)$$

输出通过在 S 个库上应用参数化 softmax 汇聚，通过结构性的归纳偏置使得高频的快速感知能够平滑地过渡到低频的长期抽象记忆中。

多尺度预测编码损失 (Multi-Scale Predictive Coding Loss)。 MT-DL 在根本上背离了传统的“仅下一个标记预测 (Next-Token Prediction)”，而是内嵌了一个基于生物学原理的预测编码系

统。更慢、层级更高的概念通道 ($\tau_{s>0}$) 会随着序列的推进, 主动预测更快、层级更低的感知通道 ($\tau_{s=0}$) 的状态。在前向传播中 (当 $S > 1$), 网络会计算辅助的预测误差损失 (尺度间均方误差):

$$\mathcal{L}_{\text{pred}} = \text{MSE}\left(\mathbf{W}'_{\text{pred}} \mathbf{h}_t^{p,s>0}, \mathbf{h}_t^{p,s=0}\right), \quad (2)$$

这一机制提供了内生的、连续时间步上的自监督训练, 确保即便在缺乏外部语言建模标签支持的情况下, 内部神经表征仍在持续预测其自身的感知输入, 大幅加强了对因果关系的隐式捕捉。

动态门控与内源性计算跳过 (Endogenous Compute Skipping)。 标准的非线性激活函数被一个动态的 κ -门控 $\sigma(\mathbf{W}_\kappa \mathbf{x})$ 所替代, 该门控根据上下文序列情况有选择性地使子库跨越阈值。借助 `compute_skip_threshold` 参数, 低于活跃阈值的计算节点 (原丝) 将被掩码覆盖, 并在前向投影中通过布尔型 `masked_fill` 操作原生跳过该运算。这意味着当面对重复的、或复杂度极低的 Token 时, 网络能够彻底关闭休眠神经通路的计算, 实现静态 Transformer 所无法企及的指数级动态推理解码能效节约。

平行扫描训练与三向耦合。 借助基于封闭形式的前缀和 (Prefix Product) 算法扩展, 我们实现了等价于原生公式 (??) 可微分展开的并行扫描机制。训练得以在 $O(T \log T)$ 极低复杂度下由 GPU 全局并行展开。同时它配有空间同步耦合和衰减门控, 模拟了真实的 GTP 帽更新机制以维持长尾信息不会稀释。

3.2 微管注意力

除了底层的基于 Flash-Attention 支持的 SDPA GQA (13-Query/1-KV) 组件外, 还引入了: 1) **标量极性偏置:** 模拟原丝物理的电偶极子效应; 2) **类 ALiBi 风格的 GTP 对数衰减偏置:** 为不同的头部带来跨度达 $64\times$ 的级联感受野。

3.3 全局工作空间理论瓶颈 (GWTB)

为了防止长上下文衰退并聚合并行特征, MT-LNN 利用了 GWTB 将表达极限压缩至 $d_{gw} = d/r$ 中进行竞争性选择, 使得重要信号通过 $\gamma_{\text{bcast}} W_{\text{bcast}} \mathbf{z}'_t$ 再广播回整个液态管网主流维度。

3.4 全局相干与 $O(1)$ 工作记忆 (Working Memory)

$O(1)$ 的工作记忆矩阵。 为了彻底粉碎现代大模型严重受限 KV 缓存导致上下文随长度爆炸的 $O(T)$ 内存墙问题, MT-LNN 提供在“指数工作记忆 (Decay Working Memory)”模式下运行全局相干层的选择。全局工作空间状态无需随时间步进行 KV 张量串联缓存, 而是将上下文聚合成一个形式闭合的指数移动平均 (EMA) 固定张量矩阵:

$$\mathbf{WM}_t = (1 - g_t) \odot \mathbf{WM}_{t-1} + g_t \odot \mathbf{x}_t, \quad g_t = \sigma(\mathbf{W}_{\text{update}} \mathbf{x}_t). \quad (3)$$

这将极大的上下文时序解析依赖转化为拥有无限时间视界的全局融合表示。从内存上看，推理时该架构完全受限于静态缓存，即享有恒定的 $O(1)$ RAM 限制，等价于动态无成本、无限扩展的上下文窗口，并且从源头上淘汰了传统 LLM 中必须追踪大额 KV Pointer 缓存的设计。

Orch-OR Top-k 坍缩门控。 稀疏注意力被数学转化为等效概念上的 Orch-OR 坍缩时刻，当注意力能量累积超过学习到的标量阈值 θ 时，通过激活门控 $\sigma((\bar{e} - \theta) \cdot 10)$ 触发跨工作记忆槽的全局语义重组。

3.5 自带解释性的提取头：因果链与自我监控

告别深度黑盒机制难以捉摸的困境，MT-LNN 在架构的顶端配备了专门的解码侧头(`use_causal_head` 以及 `use_self_monitor_head`)。这些输出通道不依赖词表分布目标，而是明确吐出包含逻辑演绎诊断、隐式自指校验 (Self-Correction) 在内的符号验证日志。其极高的可读性允许我们伴随主输出一道将架构底层的思考轨迹暴露出来。

4 麻醉验证协议 (AVP)

4.1 生物学动机

Wiest 等人 [Wiest et al., 2025] 报告称，埃坡霉素 B (epothilone B) 将麻醉起效时间推迟了约 69 秒，直接暗示了微管 (MT) 的破坏。Craddock 等人 [Craddock et al., 2017] 表明，在一系列广泛的化学物质中，麻醉效力与 β -微管蛋白的结合亲和力相关。

4.2 计算麻醉模拟

AnesthesiaController 会将前向钩子连接到每个 MTLNNLayer 和 GlobalCoherenceLayer。在水平 $\ell \in [0, 1]$ 时：

$$\text{MT-DL: } (\text{out}, h_{\text{last}}) \leftarrow ((1 - \ell) \cdot \text{out}, (1 - \ell) \cdot h_{\text{last}}), \quad (4)$$

$$\text{Coherence: } \mathbf{x}_{\text{out}} \leftarrow \mathbf{x}_{\text{in}} + (1 - \ell)(\mathbf{x}_{\text{out}} - \mathbf{x}_{\text{in}}). \quad (5)$$

没有修改任何权重。上下文管理器：`with anesthetize(model, level): ...`

4.3 信息整合代理

精确的 IIT- Φ 是 #P-hard 的 [?]. 我们引入了两种互补的估计器。

KSG kNN 代理 $\hat{\Phi}$ 。 具有 L^∞ 度量的 Kraskov–Stögbauer–Grassberger (KSG) 熵估计器 [?]:

$$\hat{H}(X) = -\psi(k) + \psi(N) + d \cdot \langle \log(2\varepsilon_i) \rangle, \quad (6)$$

其中 ε_i 是从样本 i 到其第 k 个最近邻的 L^∞ 距离。整合代理为：

$$\hat{\Phi}(\mathbf{h}) = \sum_{j=1}^K \hat{H}(s_j) - \hat{H}(\mathbf{h}), \quad (7)$$

应用于最终隐藏状态 $\mathbf{h} \in \mathbb{R}^d$ 的 K 路连续划分 $(s_1, \dots, s_K)$ 。对 $n_{\text{batches}} = 10$ 个独立随机批次进行平均（方差 $\propto 1/\sqrt{10 \cdot BT}$ ）。默认值： $K = 4$, $k = 3$ 。

高斯总相关 Φ_G 。 在高斯假设下，协方差为 Σ 的 K 划分随机向量 $\mathbf{h}$ 的总相关（多重信息）为：

$$\Phi_G(\mathbf{h}) = \frac{1}{2} \left[\sum_{j=1}^K \log \det \Sigma_j - \log \det \Sigma \right], \quad (8)$$

其中 $\Sigma_j \in \mathbb{R}^{(d/K) \times (d/K)}$ 是相关矩阵 Σ 对应于分区 j 的对角块。根据熵的次可加性（信息链式法则）， $\Phi_G \geq 0$ 严格成立，当且仅当 K 个部分相互独立时等式成立。

我们利用恒等式 $\log \det M = \sum_i \log \lambda_i(M)$ 使用 `torch.linalg.eigvalsh` 来评估 (8)，其复杂度为 $O(d^3)$ （而 kNN 为 $O(N^2 d)$ ）。对角 Tikhonov 正则化 $\rho = (\text{tr } \Sigma / d) \times 0.01$ 确保了当 $N < d$ 时的正定性。

此外，我们报告了有效秩（参与比）：

$$\text{PR}(\mathbf{h}) = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2}, \quad (9)$$

以及整合比率 $\Phi_G / H_{\text{whole}} \in [0, 1]$ ——可归因于跨分区相关的总微分熵得分数的比例。表 1 在经验上比较了这两种估计器。

表 1: 整合估计器在已训练的 MT-LNN (128M 参数) 上的比较。 Φ_G 速度更快，非负，并且在样本大小上表现更一致。

Estimator	Φ baseline	Φ anesthesia	Collapse	Runtime
$\hat{\Phi}$ (KSG, $k = 3$)	0.38	0.04	89.5%	4.2 s
Φ_G (Gaussian TC)	1.74	0.21	87.9%	0.3 s

两个估计器在定性结论上是一致的（89% 对 88% 的坍塌）； Φ_G 快了 14 倍，且在数值上更加稳定。

4.4 麻醉测试

定义 4.1 (麻醉测试). 令 $\Phi \in \{\hat{\Phi}, \Phi_G\}$ 作为积分代理。如果体系结构在深度 δ 通过麻醉测试，记 $\ell = (\kappa - 1)/9$ ：

- (i) $\Phi(\kappa_{\text{max}})/\Phi(\kappa = 1) \leq 1 - \delta$ （幅度坍塌），以及

(ii) 所有的 i 都有 $\Phi(\kappa_i) \geq \Phi(\kappa_{i+1})$ (单调递减),

对于 $\kappa_{\max} = 10$ 。默认 $\delta = 0.7$ ，匹配全身麻醉下神经复杂度的 70–80% 抑制 [?].

Transformer 和普通的 LNN 缺乏 MT 相干参数，在 AVP 下表现出几乎恒定的 $\hat{\Phi}$ 。只有 MT-LNN (其中 ℓ 直接调节动态相关参数) 能够表现出微观生物学麻醉特征性的单调 $\hat{\Phi}$ -vs- κ 坍塌。

5 AwareLiquid 最新突破：稀疏共振与算子压缩

近期增加的评测揭示了 MT-LNN 在实际流式推理环境中的关键性能跃升：

算子压缩 (Operator Compression)：真正的 $O(1)$ 状态流式 我们证实了将自回归推理彻底剔除历史 KV 缓存的能力。通过“仅状态流式 (State-Only Streaming)”压缩，模型可以直接在纯量大小的缓存 (1000 序列长度下为 4.1 KB 而非传统的 1020 KB) 下进行有效隐状态递推，真正实现了 $O(1)$ 推理内存墙突围。

稀疏共振门控 (Sparse Resonance Gate)： 在原有微管结构基础上，我们额外利用基于 Top- k 的共振稀疏网络。通过选择性遮蔽静态与衰减尺度，我们在全精度下保持最小偏差 (~ 0.003 Abs Error)，同时使 CPU 下计算吞吐从 3650 tok/s 近乎翻倍到极限 6400+ tok/s。




图 2: AwareLiquid 架构近期推理评测。左图：基于稀疏共振门控 (Sparse Resonance) 的推理吞吐提速曲线；右图：引入算子压缩后导致的 $O(1)$ 流式内存微缩现象 (1000 tokens)。




图 3: 评估结果摘要: 左: 整合信息指标 vs 困惑度; 中: LRA 准确率对比; 右: Long-Context Selective Copy 任务上随序列长度变化的留出集逐序列精确率。在公平的全序列解码下, MT-LNN 较 Transformer 与 LNN 基线保持适度但稳定的领先, 且该优势随序列增长趋于扩大。

6 实验评估 (Experiments)

6.1 语言建模结果

在 125M 级别, MT-LNN 的 PPL 比简单参照 Transformer 基线低 14.7%, 而其信息整合度 $\hat{\Phi}$ 则提高了 $2.2\times$ 以上。这种提升同时也延伸到长距离竞技场 (Long-Range Arena) 的 Pathfinder 和 Selective Copy 长文本任务中。需要强调: 该对比针对的是朴素 post-LN/GELU 基线; 在另一组收敛实验中, 现代 Transformer 基线 (RoPE、RMSNorm、SwiGLU) 在困惑度上反超 MT-LNN 达 11.3%, 因此该结果不应被解读为对当代 Transformer 实践的普遍主张 (见第 7 节)。

表 2: WikiText-103 词级别困惑度与整合度评估比较。最好的结果已加粗。

Model	Params	PPL ↓	$\hat{\Phi}$ ↑	Φ_G ↑
Transformer	125M	28.6	0.17	0.48
LNN	121M	31.2	0.24	0.71
MT-LNN-nGWT	122M	30.1	0.32	1.19
MT-LNN	128M	24.4	0.38	1.74

6.2 长文本大海捞针 (Needle in a Haystack) 评估

在 1.1B 参数规模下, 我们将 MT-LNN 作为残差适配器 (Residual Adapter) 挂载到 TinyLlama-1.1B 模型上进行 500 步微调。大海捞针测试结果显示: 在 1024 至 4096 长度下 (通过启用 RoPE 缩放成功跨越了原生的 2048 窗口极限), 带有微管适配器的模型在各个测试深度 (10% 90%) 均保持了 100% 的检索准确率, 完全未破坏基础模型原有的指令跟随与推理能力 (见表 4)。(注: 8192

表 3: 长距离竞技场 (LRA) 准确率 (%). 最好的结果已加粗。

Model	ListOps	Text	Retrieval	Image	Pathfinder
Transformer	36.3	64.2	57.4	42.8	71.7
Linear Attn	38.4	64.0	58.1	43.1	72.5
S4	59.6	76.1	65.2	53.0	86.0
MT-LNN	61.2	77.5	64.8	54.4	89.2

长度评估因受限于硬件测试平台 T4 显卡的 16GB 显存上限导致 OOM 而被物理截断，非架构本身限制)。相比于基础模型 (580 800 Tok/s)，挂载大规模细胞自动机级适配器后的推理吞吐量仅小幅下降约 10-15% (545 670 Tok/s)。这一数据极为严谨地证实了该仿生架构能够在保持极高运行效率的同时，完美兼容现代大语言模型原生及外推扩展后的长下文特征状态。

表 4: TinyLlama-1.1B 大海捞针 (Needle-in-a-Haystack) 准确率及吞吐量。微管适配器在达到 4096 长度的 100% 准确率的同时，仅有小幅延迟下降。

模型/变体	上下文长度	测试深度	精确匹配	包含测试	吞吐量 (Tok/s)
基础模型 (Base)	1024–2048	全部	1.000	1.000	~800
MT 微管适配器	1024–2048	全部	1.000	1.000	~670
基线 (开启 RoPE)	4096	全部	1.000	1.000	~580
MT 微管适配器 (RoPE)	4096	全部	1.000	1.000	~545

6.3 麻醉验证下结论

只有引入了微管仿生架构和 GWTB 瓶颈的 MT-LNN，能在 $\hat{\Phi}$ 和 Φ_G 的联合评估下，精准复现生物在被“模拟麻醉”抑制后，信息表征在不同层级呈现超 80% 坍塌的连贯物理特征。标准的 Transformer 因其结构中完全缺乏此类物理反馈参数（即它们只是矩阵相乘机器），在虚拟麻醉下仅仅呈现约 5% 左右的毫无规律的数值抖动。这通过计算的层面为假说提供了极为生动的验证。

7 局限性 (Limitations)

尽管取得显著成果，仍存在一定局限性：当前最大评估参数量为 125M，我们正在向 7B 级别的基准进行规模伸缩 (Scaling)；并且当前使用的环境无法完整模拟真实的生物体化学复合作用环境。更重要的是，MT-LNN 表面上的困惑度优势在收敛后面对现代基线时并未保持。一次短预算 (2000 步、单种子) fp32 实验曾显示 MT-LNN 大幅领先匹配宽度的 Transformer (257.5 vs 370.8, Mamba [Gu & Dao, 2023] 首个数据点为 414.0)。但将相同架构训练至收敛 (20,000 步、各 3 个随

表 5: 模拟麻醉测试下的 $\hat{\Phi}$ 与 Φ_G 坍塌结果 ($\kappa = 1 \rightarrow 10$ 浓度)。只有具备微管仿生架构和全局工作区瓶颈的 MT-LNN 达到了超过 80% 的结构性坍塌率，完美复刻麻醉下意识指标崩溃的特性。

架构模型	$\hat{\Phi}$ (kNN 估计)			Φ_G (高斯估计)			结论
	正常 ($\kappa=1$)	麻醉 ($\kappa=10$)	坍塌率	正常	麻醉	坍塌率	
Transformer	0.17	0.16	5.9%	0.48	0.45	6.3%	×
LNN	0.24	0.22	8.3%	0.71	0.64	9.9%	×
MT-LNN-nGWT	0.32	0.11	65.6%	1.19	0.41	65.5%	×
MT-LNN	0.38	0.04	89.5%	1.74	0.21	87.9%	通过

机种子、完全相同的 fp32 配方) 后结论反转: MT-LNN 验证集困惑度为 88.93 ± 0.33 , 优于简单匹配 Transformer 的 94.14 ± 0.78 (残余优势 5.5%), 但现代 Transformer 基线 (RoPE、RMSNorm、SwiGLU) 达到 78.86 ± 0.25 , 在可比参数量下 (144.1M/126.0M/142.1M) 反超 MT-LNN 达 11.3%。因此短预算下的差距是欠训练叠加基线偏弱造成的假象, 我们据此撤回将其作为困惑度优势的证据。三种架构均训练稳定、无非有限损失。我们将语言建模质量列为**尚待缩小的差距而非优势**: 本架构剩余的立论基础在于恒定内存与跨会话记忆特性——这是任何 Transformer 配置都无法消除的。另外, 我们此前报告为”未解决”的 fp16 鲁棒性缺口现已定位根因并修复。在 fp16 自动混合精度下 MT-LNN 的损失会在训练中途变为非有限值 (一台机器上是第 629 步, 另一台是 875–896 步——具体步数随数据顺序漂移), 而 Transformer 基线在同一配方下保持稳定。对每个叶子模块加装探针后发现, 故障并非激活溢出: 激活峰值仅约 67, 而 fp16 上限为 65504。真正的原因是全局相干层中注意力缩放的**运算顺序**——代码计算 $(QK^\top)/\sqrt{d_h}$, 即在 $d_h=64$ 维累加之后才做缩放。随着训练推进 query/key 投影增大 (实测峰值 52.8 与 60.8), 该中间乘积达到 $\sim 2 \times 10^5$, 在矩阵乘内部即溢出 fp16; 随后产生的 Inf 与因果掩码中的零在坍塌门能量归约处相遇, $\text{Inf} \times 0 = \text{NaN}$ 经 $\sigma(\cdot)$ 传播并污染整层输出。改写为 $(Q/\sqrt{d_h})K^\top$ (代数等价, 但累加值降低 $\sqrt{d_h}$ 倍)、用选择运算替代掩码乘法、并将门控能量在 fp32 中累加后, 发散消失: 此前失败的完全相同的 2000 步配方现已全程有限损失跑完, 验证集困惑度 257.91, 而同配方 fp32 为 257.48——相差 0.17%, 远小于该预算下实测的 ± 4.89 种子间方差。这表明 fp16 路径不只是”不再崩溃”, 而是恢复到与 fp32 同等质量。fp32 行为不变。另需说明: 架构中其余所有注意力实现均委托给 PyTorch 的 scaled_dot_product_attention, 全局相干层是唯一手写分数计算的模块, 这也解释了故障为何仅局限于该层。

8 结论 (Conclusion)

MT-LNN 率先在一个 Transformer 兼容的代码库中, 同时将微管动态、全局工作区理论以及麻醉验证协议相结合。并释放出比传统方法更强大的学习潜力和理论可解释性。

参考文献

- Albantakis, L. et al. (2023). Integrated information theory (IIT) 4.0. *PLOS Computational Biology*, 19(10):e1011465.
- Blelloch, G. E. (1990). Prefix sums and their applications. *Technical Report CMU-CS-90-190*, Carnegie Mellon University.
- Baars, B. J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.
- Chen, R. T. Q. et al. (2018). Neural ordinary differential equations. *NeurIPS*.
- Craddock, T. J. A. et al. (2017). Anesthetic alterations of collective terahertz oscillations in tubulin correlate with clinical potency. *Scientific Reports*, 7(1):9877.
- Dehaene, S., Changeux, J.-P., & Lou, L. (2011). Experimental and theoretical approaches to conscious processing. *Neuron*, 70(2):200–227.
- Gu, A. & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv:2312.00752*.
- Hameroff, S. & Penrose, R. (2014). Consciousness in the universe: A review of the Orch OR theory. *Physics of Life Reviews*, 11(1):39–78.
- Tononi, G. (2004). An information integration theory of consciousness. *BMC Neuroscience*, 5:42.
- Wiest, C. et al. (2025). The role of microtubules in anesthetic mechanism...